

## ИДЕНТИФИКАЦИЈА

⑩ Задаток јавис идентификације. Примена и начин спроведења. Поступак идентификације.

Идентификација је одређивање на основу улазних излазних сигнала, модела из одређене класе модела који је еквивалентан процесу на коме су извршена мерења. ✓

Примена: \* формирање машин. модела аматерских и динамичких

\* саставни је део сајемских ѕекција аутонашкот управљања

Спроведење: \* offline (независно се користи ој рада аматера)

\* online (користи се јаком - - -)

\* real time (слично online, али се користи некон склоне методе обасирани) ✓

Модели: \* graybox (шарнира одреди одлик, а мерење непознате детаље модела)

\* whitebox (искључиви изградњи)

\* blackbox (нашао искл. на основу мерења)

Поступак: \* утвђивање структуре модела

\* детаљни саје пример. експ. ✓

\* мерења

Детаљни саји и кораки из чланка идентификације!

1. Напади се експеримент и прати се улазни/излазни подаци
2. Формирање ћојашака
3. Детаљни саје класе модела
4. Израчунат се конкретни модел на основу ћојашака и детаљни саји
5. Испитивање осудење модела
6. Чакајући модел не задава. Експ. се  $4 \rightarrow 3 \rightarrow 2 \rightarrow 1$

Шта одређује резултат? \*

- одређује га стварају атица сенса усума,

$$\varepsilon = y - \bar{s}g$$

$$\varepsilon = y - \bar{s}\hat{g}$$

$$\varepsilon = y - \bar{s}g^1$$

$$\varepsilon = y - \bar{s}\hat{g}$$

Шта је особина идентична битности?

- одређује га ли се паралелни нодови могу одредити

- нодови су је идентични, ако су φ-је зависности нодова  
сталне ✓

Разлика између идентичности и φ-је зависности

$$\varepsilon = y - \bar{s}g$$

Методе параметарске адекватности

#помошник смја бисали

#на процену параметра учину удејство преношавање

- Параметарска адекватност је одређивање модела који је сличан са проценом коју до неизнатих параметара

- Укупна грешка се изразљије као сума разлике измера излаза и улаза модела

$$J(g) = \frac{1}{2} \sum_{k=1}^n (y_{uk} - g_{uk})^2 = \frac{1}{2} \sum_{k=1}^n (y_{uk} - q_{uk})^2$$

Укупн - разлика  
измерених  
из мерења

- Потребан услов за минимум:

$$\nabla J = \frac{\partial J}{\partial g} = - \sum_{k=1}^n e_k \cdot u_k = - \sum_{k=1}^n (y_{uk} - q_{uk}) u_k = 0$$

укупн - процене  
излаза

$$\sum_{k=1}^n u_k^2 \cdot \hat{g} = \sum_{k=1}^n y_{uk} \cdot u_k \Rightarrow \hat{g} = \frac{\sum_{k=1}^n y_{uk} u_k}{\sum_{k=1}^n u_k^2}$$

#процена  
параметра

$$S^T S = \hat{g} = S^T Y$$

$$\hat{g} = (S^T S)^{-1} S^T Y$$

#процена неизв.

#Ово је ширијашки метод

#ширијаш. алгоритми су јужинов и Градивештићи  
Парам. адекв. неизв. неизв. параметар

- Укупна грешка:  $J(g) = \frac{1}{2} \sum_{k=0}^{K-1} e_k^2(g)$

- Грешка:  $e_k(g) = y_{uk} - g_{uk}, g$

Линеарни модел:  $y(t) = g \cdot u(t)$

када довољимо неколико мережа улаза  $x$  и

$$\Rightarrow S = [u_1 \ u_2 \dots \ u_K]^T$$

$$Y = [y_1 \ y_2 \ \dots \ y_K]^T$$

## #42 Параметарска идентификација и НИК (LS оцеништво)

1) Пример на дела

- а се је  $t$  ге је излаз мереар ће непознатим параметрима

$$y(t) = \Phi(t) \cdot g + v(t)$$

2) Процена више параметара преко НИК

- базира се на процеси једног параметра, процена се виши и ступа, иако је непознатих параметар и исто толико већа које зависе од т улаза

3) Непомерена процена параметара

- спр. лр. процене:  $E[\hat{g}] = g + (S^T S)^{-1} S^T E[N]$

- процена параметар је непомерена када је

$E[\hat{g}] = g + 0$ , а то значи када је шум дели

4) Ефикасна -II-

- за лемки сп. мерена к бачи да расчитаје процене  $E[(g-\hat{g})(g-\hat{g})^T] = 6g^2$  шуми шуми,

$$\lim_{K \rightarrow \infty} 6g^2 \rightarrow 0$$

✓

5) III аче прегу. параметра:

- процена је виша када је непомерена и ефикасна

услови: дели шум + лемки сп. мерена к ✓

$$S = \begin{bmatrix} P_{11} & \dots & P_{1P} \\ P_{21} & \dots & P_{2P} \\ \vdots & \ddots & \vdots \\ P_{K1} & \dots & P_{KP} \end{bmatrix} = \begin{bmatrix} \Phi_1 \\ \Phi_2 \\ \vdots \\ \Phi_K \end{bmatrix}$$

1. бени шум  
специјал  $\text{Ep.} = 0$

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

2. амплитуда генератора = 1

$$\delta = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

3. аутокорелација = 0      више не корелирају

$$R(k) = \frac{1}{(N-k)\delta^2} \sum_{i=1}^{N-k} (x_i - \mu)(x_{i+k} - \mu)$$

7) Генератор усагласи се:

- синус  у склопу

- процес је динамички

- овоје можемо бити шум

8) Објективни шум

- годија се убрзашавају нови шуми из савремене

индустрије који су високо преносни

δ) комбинује неколико посредних предности

9) Шта је усагласи бити ако си налази у њега се користи?

- брзина која се користи са  $\text{Ep.} (-\alpha, -\alpha)$  који се најчешће налази у таком преносу од бирача.

Користи се као улаз у неприменији динамички

модел

10) Од које ф-је креће МНК?

$$J = \frac{1}{2} \sum_{k=1}^m e_k^2 \quad e_k - \text{Погрешка}$$

## #43 Идентификација ARX модела

- дефиниција

ARX је временски дискретан машински модел

$$A(z)y(k) = B(z)u(k) + v(k)$$

$y$  - излаз,  $u$  - улаз,  $v$  - бели шум

$A(z), B(z)$  - полиноми  $\text{у}o z = e^{st}$

- кадом настоди се идентичкују параметри ARX модела?

- МНК, јер је излаз линеаран по неизвесним параметима. кади ако је равнија предискин

$$y(k) + a_1 y(k-1) + \dots + a_n y(k-n) = b_0 u(k) + \dots + b_{m-1} u(k-m) + v(k)$$

#Идентиф.

$$\hat{g} = (S^T S)^{-1} S^T Y$$
 је процесац предискин параметра

- модел је линеаран по параметима и параметри се могу идентификовати

- то се често користи

- изаберите се минимални редни

- је случај када се загадују улази и излази

- неких случају се догаја позадина чинијем. предискин

- измери се излаз  $Y(k)$  и израчунат чинијем. (P.)

$$y(k) = Y(k) - Y_0$$

кашњење улаза ARX модела

$$A(z)y(t) = B(z)u(t - \Delta t) + v(t)$$

$$A(z)y(k) = z^{-d}B(z)u(k) + v(k), \text{ улаз наши 39}$$

$\delta t = d \cdot T \Rightarrow$  ако то значи да си не морамо  
изделији који су др. б параметар, ако  
не позицију кашњење, б парам. се издаји,  
ако им је предност = 0

#44 Идентификација ARMAX модела

- генерирања

- I -

$$A(z)y(k) = B(z)u(k) + C(z)v(k)$$

- II -

- узимају се осједи

$$y(k) + a_1y(k-1) + \dots + a_ny(k-n) = b_0u(k) + b_1u(k-1) + \dots + b_mu(k-m) + v(k) + c_1v(k-1) + \dots + c_rv(k-r)$$

- издавају се

- уз параметре пољнома се симулише појаснији исход, па  
не можемо применити МНК огњак, да се реализује

у 2 корака:

1) Најпре се агенцијски ARX модел и процесе  
који се паралелно

2) Процеси се узимају и оптимизирају параметри ARMAX

- ређају ARMAX

- оптимизирају парам. се покреће линеарна  
за разне конф. пољнома A и B и посматра се  
ке су добијени узимају се доbro оптимизирани модел

## #43 Идентификација ARX модела

- дефиниција

ARX је временски дискретан машински модел

$$A(z)y(k) = B(z)u(k) + v(k)$$

$y$  - излаз,  $u$  - улаз,  $v$  - бели шум

БЕЛИ ШУМ

$$A(z), B(z) - полиноми \text{ и } z = e^{st}$$

- когод мешовитим се идентификују параметри ARX модела?

- МНК, јер је излаз линеаран по неизвестним параметрима. када имамо равноточни предисци

$$y(k) + a_1 y(k-1) + \dots + a_n y(k-n) = b_0 u(k) + \dots + b_m u(k-m) + v(k)$$

#Идентиф.

$$\hat{g} = (S^T S)^{-1} S^T y$$
 је проценета предисција параметара

- модел је линеаран по параметрима и предисцијама. се могу идентифицирати

- постапајући неправилно

- изадре се линеаран рејон

- је дискип. идентификација  $t = k \Delta t$  се задају улази и излази

- неки. улази се додају дозада чинијем. предисциј

- измери се излаз  $y(k)$  и израчуна чинијем. LP.

$$y(k) = y(k) - y_0$$

МАНО J, је што најујујујући поимона

Како се процесује ћемо шуму у издатку.

$$A(z)y(k) = B(z)u(k) + C(z)v(k) \quad ||C(z)|$$

$$\frac{A(z)}{C(z)} y(k) = \frac{B(z)}{C(z)} u(k) + v(k)$$

$$G(z)y(k) = H(z)u(k) + v(k)$$

- МНК издатак. стапаше  $G(z)$  и  $H(z)$

- изравнише

$$(v(k) = G(z)y(k) - H(z)u(k))$$

Кашњење улаза ARMAX могућа

$$A(z)y(k) = z^{-d} B(z)u(k) + C(z)v(k)$$

Процена параметара.

$$\hat{\theta} = (S^T S)^{-1} S^T y$$

## 4.5: Идејни начинирају променљивих параметара РМНК

### 1) Погодност РМНК

- када се параметри мењају шоком рада система, не могу се користи МНК, него РМНК
- брже заступљаве и мање мерене
- on-line i real-time идеји.

### 2) Идеја РМНК

- за оглед.  $\hat{g}(k+1)$  је датумски посједују процјену параметра.  $\hat{g}(k)$  и коришћени је на основу нових података излаза:  $y(k+1)$  и улаза (додатој у  $\Phi(k+1)$ ):

$$\hat{g}^*(k+1) = \hat{g}^*(k) + P(k) \Phi(k+1) (y(k+1) - \Phi^T(k+1) \hat{g}^*(k))$$

шкунска  
процјена      прештодна  
коренчној  
текстор      којо  
мерене  
предијесног  
периода

### 3) Кораки РМНК

1) примичује се нуле предишњији и  $u(k+1)$  и  $y(k+1)$

2) формира се  $\Phi(k+1)$

3) израчују се  $P(k+1)$

4) израч се  $\hat{g}^*(k+1)$

5) мерију се  $P(k)=P(k+1)$  и  $\hat{g}(k)=\hat{g}^*(k+1)$  39

напредни штремутак

4) идејнији. пропна параметар. подела

- ако се параметар. подела мењају шоком рада система, тада ће оно постати је први у реалном врем. и штада ће бити оно да су већностим сконцентрирана

5) фактор заборављања

- то је параметар. јер се користи у ф-ју чува за рекурз. методунки када ћелио да дано мало значај грешак

$$\text{Меренчина} \Rightarrow J_D = \frac{1}{2} \sum_{i=0}^k f^{h-i}(y_i - u_i^\top g)^2$$

✓ 46 + 47

Итеративне методе. Гаус-Нютонов алгоритам,  
Градијентни и Неландер-Марквардов алгоритам

Користи се за моделе који су нелинейни  
и/или непознатим параметром.

- осмисля се итеративни и брз. дистрејшан  
есоцем

$$- осмисламо: x(k+1) = f(x(k), u(k), q)$$

$$y(k) = g(x(k), u(k), q)$$

- користимо да процектујемо вредност  $\hat{g}$ , који се бризу  
 време критеријуму стапања:

$$J(g) = \frac{1}{2} \sum_{k=0}^{K-1} e_k^\top g e_k(g)$$

е-пешка

$$e_k(g) = y_r(k) - y(k, g)$$

$y_r(k)$  - примерни излази едног

$y(k, g)$  - - - излази модела

- неких односу је гедитивни  $\oplus$  је осећављивост

$$J(g) = \frac{1}{2} \sum_{k=0}^{K-1} e_k^2(g) \text{ је укупна пешка}$$

- врати се  $\hat{g}$  за који је  $J \min$ , и ти чеку се  
 $\min J$  добија итеративно

$$g_{n+1} = g_n + D g_n$$

- решени нправа:
- 1)  $\|g_n\| < \varepsilon_g$
  - 2)  $J(g_n) < \varepsilon_J$
  - 3)  $n \leq n_{\max}$        $n$  - ознака итерације

Алгоритми:

① ГРАДИЈЕНТНИ АЛГОРИТАМ:

$$\Delta g_n = -h \nabla J(g_n)$$

② ЈАУС-НОУТНОВ АЛГОРИТАМ

$$\Delta g_n = -(S^T(g_n)S(g_n))^{-1} \nabla J(g_n)$$

③ ЛАВЕНБЕРГ - МРКАРТ АЛГОРИТАМ

$$\Delta g_n = -(S^T(g_n)S(g_n) + \lambda_n I)^{-1} \nabla J(g_n), \text{ где се } \lambda_n$$

меша