


Veštačké neuronske mreže

Osnovni koncepti

Šta je konekcionizam?

- ❑ KONEKCIIONZAM je teorijsko stanovište ili pravac u kognitivnoj nauci koji želi da objasni ljudske intelektualne sposobnosti konstruisanjem veštačke neuronske mreže.
- ❑ MOZAK čoveka sadrži nekoliko tipova nervnih ćelija ili neurona. Ukupno čovekov mozak ima 10^{11} neurona koji ostvaruju 10^{15} konekcija.
- ❑ INDIVIDUALNE ĆELIJE komuniciraju tako što prenose signal (celularna transdukcija) iz jedne ćelije u drugu, uz pomoć neurotransmitera (serotonin, dopamin, acetylholin, adrenalin, i dr.).

Prirodni (biološki) neuron



Cilj:

Definisati osnovne principe pomoću kojih se neuronske mreže matematički opisuju.

Principi proizilaze iz realnog sveta – biologije.

Matematički aparat služi da bi na što bolji način opisao prirodu i ponašanje neurona.

Karakteristike neuronskih mreža (NM)

Mogu da se podele u dve grupe:

- Arhitektura
- Neurodinamika

Arhitektura

Definiše strukturu NM, kao što je broj neurona i način njihove međusobne povezanosti.

Neuronske mreže se sastoje od određenog broja međusobno povezanih neurona, procesnih elemenata, sa sličnim karakteristikama kao što su: ulazi, sinapse, sinaptičke težine, aktivacija, izlazi, bias, ...

Neurodinamika

Definiše osobine u smislu “ponašanja” NM, odnosno, kako NM uče, podsećaju se (pozivaju naučeno), vrše grupisanje (pridruživanje podataka), upoređuju nove podatke sa već postojećim znanjem, kako klasifikuju nove informacije i kako razvijaju novu klasifikaciju, ako je to potrebno.

- Veštačke neuronske mreže (VNM) vrše **procesiranje** informacija.
- Ideja je da to čine **paralelnim** procesiranjem a ne sekvencijalnim algoritmima.
- Paralelno procesiranje znači da se ulazna informacija “razlaže” i **istovremeno** obrađuje u više različitih neurona (elemenata)
- U zadnjih nekoliko desetina godina je uložen veliki rad da bi se projektovale elektronska kola koja bi **ličila** na biološke NM sa svim pripadajućim karakteristikama.
- Na taj način su razvijeni različiti modeli NM poznati pod nazivom - **PARADIGME**

- Svi modeli VNM se tradicionalno opisuju **diferencijalnim** (diferencnim) jednačinama.
- I najbolje projektovane VNM su daleko **inferiorne** i od najprimitivnijih oblika života.
- VNM ipak predstavljaju veoma **ozbiljan** pokušaj da se spozna način na koji funkcionišu biološke NM, a posebno mozak.

Sada se postavlja pitanje:

Kako upotrebiti matematiku da bi se opisali principi rada neurona?

Matematika je dobra za sekvencijalnu obradu podataka ali biološke NM ne rade sekvencijalno, a ne znaju ni matematiku.

Ipak, BNM su u nekim slučajevima sposobne da urade nešto što ne može ni najsavršeniji računar.

Primer:

$$100 : 3 = 33.33$$

$$3 * 33.33 = 99.99 \neq 100$$

Međutim, može se uzeti kanap dugačak 100cm i jednostavno podeliti na tri dela.

BNM je rešila problem koji računar ne može.

Modelovanje

Da bi se razvio model VNM potrebno je razviti **matematički model** koji na najbolji mogući način opisuje funkcionalnost prirodnog (biološkog) sistema.

Tada je moguće izvršiti **računarsku simulaciju** i utvrditi u kojoj se meri slažu rezultati simulacije sa realnim ponašanjem biološke NM.

Nakon simulacije se mogu vršiti **korekcije**, i to u dva pravca:

1. Ako su **rezultati loši**: promena parametara i strukture, usložnjavanje modela.
2. Ako su **rezultati dobri**: uprošćavanje modela.

Naravno, da bi se napravio dobar simulacioni model potrebno je izuzetno dobro poznavati **prirodu** pojave koja se modeluje, pa tek onda matematiku kao **alat** kojim se to čini.

- Matematika je **ljudski pronalazak** kojim se pokušava opisati priroda oko sebe
- Model je naša **predstava** o nekoj pojavi.

U svakom slučaju:

PRIRODA PRETHODI MATEMATICI

- Veliki uticaj na način i pristup modelovanju VNM je imao **najsloženiji** proces obrade podataka koji se vrši u mozgu – proces obrade **vizuelnih** informacija.

odatle potiče i veliki broj termina vezanih za VNM.

Osnovni model neurona


- Osnovni blok, sastavni element svake NM je **neuron**.
- Pošto je ovde reč o veštačkim NM (VNM) njihov osnovni element je **veštački neuron**.
- Pod ovim nazivom se podrazumeva **osnovni procesni element** VNM u smislu svoje funkcije, tj. načina rada (delovanja).
- Generalno, neuron ima **n ulaza** označenih sa **x_j ; $j=1, 2, \dots, n$** koji predstavljaju izvor (vrše indikaciju) ulaznog signala.

- Svaki ulazni signal je **otežan** (ponderisan) pre nego što preko kontaktnog elementa (**sinapse**) dođe do tela procesnog elementa.
- “Otežavanje” se vrši množenjem vrednosti ulaznog signala x_j njegovom **težinom sinapse w_j** .
- Takođe postoji slobodni član (**bias**) - w_0 i prag (**threshold**) – θ , koji određuju potrebni nivo signala za **aktivaciju** neurona.
- Nelinearna **funkcija f_j** deluje na **pobudni** signal R_j i formira **izlaz** neurona O_j .

- Funkcija f_j se naziva **aktivaciona funkcija**.
- Izlaz neurona O_j predstavlja **ulaz** za neke druge neurone.
- Kada je neuron deo VNM često se naziva **čvor** (node).
- Ako se VNM sastoji od **više čvorova**, dodaje se još jedan indeks koji služi da označi kom neuronu signal ili funkcija pripada, tako da je:
 x_{ij} – j -ti ulaz i -tog neurona;
 w_{ij} – težina j -te sinapse i -tog neurona;

- R_i – aktivacioni signal i -tog neurona;
- f_i – aktivaciona funkcija i -tog neurona;
- O_i – izlazni signal i -tog neurona;
- θ_i - prag (threshold) i -tog neurona.

Sve ovo se može predstaviti i grafički, na sledeći način ->





$$O_i = f_i \left(\sum_{j=1}^n w_{ij} x_{ij} + w_0 \right)$$



$$\sum_{j=1}^n w_{ij} x_{ij} + w_0 \geq \theta_i$$

- Osnovni razlog uvođenja nelinearne funkcije f_i u VNM jeste **ograničavanje** nivoa izlaznog signala.
- Ovaj koncept sasvim odgovara biološkom neuronu – **ne postoje** signali beskonačno velikog intenziteta.
- Najčešći tipovi **nelinearnosti** u VNM:
 - **Hard limit** (idealni prekidač)
 - **Rampa**
 - **Sigmoida**
 - **Gausijan** – zvonasta funkcija



Hard limit




Rampa



Sigmoida



Gausijan




O analitičkim izrazima ovih funkcija će biti reči kasnije

- Sigmoida je veoma **popularna** kao aktivaciona funkcija jer je:
 - **monotona**
 - **ograničena**
 - **jednostavno** joj se izračunava prvi izvod, što će kasnije biti veoma bitno.

$$f'(s) = K \cdot f(s) \cdot (1 - f(s))$$

Primer rada jednog neurona



Učenje u VNM

- Učenje je **važan** proces, kako u BNM tako i u VNM.
- **Osnovna pitanja** koje se ovde postavljaju:
 - **Kako** učimo?
 - Koji način učenja je **najefikasniji**?
 - **Koliko puno** i koliko **brzo** možemo da učimo?
 - Koje su **prepreke** u učenju?
- Istraživanja su dala mnoge odgovore na ova pitanja. Trenutno je od interesa kako uče VNM:

- Proces učenja u VNM je **proces** podešavanja promenljivih težina sinapsi (w_{ij}) u cilju postizanja odgovarajućeg (željenog) izlaza (O_i) za dati pobudni signal (x_{ij}).
- Kada je izlazni signal jednak željenom (očekivanom) tada je proces učenja završen i kaže se da je VNM **obučena**, odnosno da je “stekla znanje”.
- Obuka VNM se vrši prema algoritmima (**pravilima** obuke) koji se opisuju u matematičkom obliku - **jednačinama** obuke.
- Jednačine obuke **opisuju** proces obuke pojedinog tipa VNM.

- Pošto neuroni u VNM mogu biti povezani na **različite** načine i može ih biti različit broj, postoje i različiti primeri modela VNM (paradigme), pa i različiti algoritmi obuke.

Karakteristični tipovi algoritama obuke

- Učenje **sa nadzorom** – učiteljem (supervised learning)
- Učenje **bez nadzora** (unsupervised learning)
- **Pojačano** učenje (reinforcement learning)
- **Kompetitivno** učenje (competitive learning)
- **Delta pravilo** (delta rule - LMS)
- Metoda **opadajućeg gradijenta** (gradient descent rule)
- **Hebovo** učenje (Hebbian learning)

Osnovne karakteristike VNM su:

1. **Kolektivna** - sinergična obrada podataka (computing)

- program se izvršava kolektivno i sinergično
- operacije su decentralizovane

2. **Robusnost**

- operacije su neosetljive na slučajne poremećaje
- operacije su neosetljive na parcijalne i netačne ulaze

3. **Učenje**

- VNM automatski uspostavlja preslikavanja (asocijacije)
- algoritam rada – program, kreira VNM tokom procesa obuke
- VNM se podešava (adaptira) sa ili bez učitelja, ali svakako bez intervencije programera

4. **Asinhrono izvršavanje** (rad)

- BNM nemaju sat da međusobno usklade svoj rad. Veći broj VNM, ipak, zahteva vremensko usklađivanje.

Važniji parametri VNM

- **Perfomanse** VNM govore u kojoj meri je VNM sposobna da u procesu eksploatacije reprodukuje skup za obuku (Training, Validation, Test).
- **100% performanse** znači da VNM u procesu eksploatacije sve uzorke procesira apsolutno tačno.
- Pri obuci se uvek teži da performanse budu **što bliže 100%**, ali i tu postoje granice.

Pri projektovanju VNM je potrebno razmotriti i definisati sledeće parametre VNM:

1. Topologija VNM

Karakteristika	Feed-forward NN	Recurrent NN
Smer toka signala	Samo napred	Dvosmerno
Uvođenje kašnjenja	Ne	Da
Kompleksnost	Niska	Visoka
Nezavisnost neurona u istom sloju	Da	Ne
Brzina	Velika (brze)	Mala (spore)
Primena	Prepoznavanje oblika, govora, karaktera, ...	Prevod, konverzija govora u tekst, robotsko upravljanje, ...

2. Broj slojeva u VNM

Pri projektovanju VNM je potrebno razmotriti i definisati sledeće parametre VNM:

3. **Broj neurona** (čvorova) po sloju
4. **Usvajanje algoritma obuke**
5. **Broj iteracija** po uzorku tokom treninga
6. **Brzina rada** u eksploataciji
7. **Performanse** VNM
8. **Kapacitet** VNM - maksimalan broj uzoraka koji VNM može da nauči i kasnije pozove

9. Stepen adaptivnosti VNM – u kom stepenu je VNM sposobna da se adaptira posle okončanja procesa obuke

10. Vrednost biasa – često se unapred postavlja na neku određenu vrednost

11. Vrednost praga (threshold) - često se unapred postavlja na neku fiksnu vrednost, npr 0 ili 1.


12. Ograničenje težina sinapsi – za bolje performanse i otpornost prema šumu; često se zadaje unapred; normalizacija

- 13. Izbor nelinearne **aktivacione funkcije** i opseg aktivnosti neurona
- 14. **Otpornost** VNM na šum – stepen u kome šum (smetnja, oštećenje) na ulaznom signalu uzrokuje šum na izlaznom signalu
- 15. **Vrednost težina** sinapsi u stacionarnom stanju – stanje VNM nakon obuke

Topologije VNM


- VNM se sastoje od **većeg broja** neurona i veza među njima.
- Neke karakteristične **topologije** su prikazane na sledećim slikama.
- Kod **svih** topologija se mogu uočiti sledeći elementi:
 - **ulazni** sloj (input layer)
 - **izlazni** sloj (output layer)
 - **skriveni** slojevi (hidden layers)

Višeslojni perceptron
Višeslojna VNM sa prostiranjem signala u
napred
Multilayer Feed Forward ANN




Višeslojna kooperativno/kompetitivna VNM


Multilayer cooperative/competitive ANN



Dvoslojna VNM sa prostiranjem signala
napred/nazad
Bilayer feed forward/backward ANN



Jednoslojna VNM sa kombinovanim povratnom
spregom
Monolayer hetero feedback ANN



Modelovanje VNM

Matematičkom analizom se može doći do sledećih podataka o mreži:

1. **Kompleksnost** – koliko VNM treba da bude velika da bi izvršila zadatak
2. **Kapacitet** – koliko bita informacija se može pohraniti u jednoj VNM
3. **Izbor modela** – koji tip VNM je najpogodniji za datu primenu
4. **Performanse** – koja VNM ima najbolje performanse

5. **Efikasnost učenja** – koliko brzo VNM “uči”
6. **Odziv** – kolikom brzinom VNM daje odziv nakon dejstva signala na ulazu
7. **Pouzdanost** – da li VNM uvek daje isti odziv za istu pobudu
8. **Osetljivost na šum** – koliko tačno VNM reprodukuje željeni izlaz u prisustvu šuma
9. **Osetljivost na otkaz** – koliko tačno radi VNM ako jedan njen deo ne funkcioniše.

Obuka i programiranje VNM


Matematički opis načina kako se menjaju težine sinapsi (w_{ij}) tokom procesa obuke VNM naziva se **algoritam obuke**.

Na kraju obuke, stacionarne vrednosti težina w_{ij} definišu **program VNM**.

Načini učenja su **pozajmljeni iz prirode**, i već su prethodno navedeni (npr. obuka sa i bez učitelja)

Obuka sa nadzorom (sa učiteljem) Supervised Learning

- Iterativni postupak, zahteva više prolaza kroz skup za obuku.
- Na sledećoj slici je prikazana VNM sa učiteljem



Generalno: promena težina je proporcionalna signalu greške tokom obuke i stimulaciji (ulazu) neurona.

Obuka i -tog neurona se može opisati izrazom:

$$\frac{\delta w_{ij}}{\delta t} = \mu E_i(O_i, T_i) \mathbf{X}_i(t)$$

gde je μ mala pozitivna konstanta poznata kao **korak obuke** – learning rate

Ako se obuka vrši na digitalnom računaru pogodniji diskretni oblik jednačine:

$$w_{ij}(k+1) = w_{ij}(k) + \mu E_i(O_i(k), T_i(k)) X_i(k)$$

odnosno:

$$w_{ij}(k+1) = w_{ij}(k) + \text{iznos korekcije}$$

gde je k – broj iteracije

Algoritmi obuke

- Algoritam obuke je matematički alat koji predstavlja metod kojim će se određenom brzinom uspešno doći do stacionarnog stanja parametara - težina i pragova VNM.
- Obuka počinje definisanjem **kriterijumske funkcije** (funkcija greške) koju je potrebno minimizirati.
 - Ova funkcija se izražava preko težina i pragova VNM.
 - Na taj način se obezbeđuje da kriterijumska funkcija bude u direktnoj vezi sa promenljivim veličinama VNM.

Algoritmi obuke

- Odabir **kriterijumske funkcije** i **optimizacionog metoda** je od izuzetne važnosti, jer od njih zavisi **stabilnost procesa** obuke i opasnost od završetka obuke u **lokalnom minimumu**.
- Tokom obuke vrednost kriterijumske funkcije opada i težine se približavaju stacionarnom stanju.

Primer obuke VNM bez nadzora

T_i – vektor željenih izlaza, **ne postoji (nije poznat)**

$f = \text{sgn}(\cdot)$ – nelinearnost je bipolarna funkcija (+1, -1)

$\mathbf{w}_{ij} = [w_{i1} \ w_{i2} \ \dots \ w_{in}]$ – vektor težina ulaza i -tog neurona, na početku obuke male pozitivne i negativne vrednosti

$\mathbf{x}_{ij} = [x_{i1} \ x_{i2} \ \dots \ x_{in}]$ – vektor ulaza i -tog neurona

μ – korak učenja; mali, pozitivan broj

k – broj iteracije

$$O_i(k) = f \left(\sum_{j=1}^n w_{ij}(k) x_{ij} \right)$$

$$\Delta w_i = \mu O_i(k) x_{ij}$$

$$w_i(k+1) = w_i(k) + \mu O_i(k) x_{ij}$$

VNM i problem klasifikacije

Obučena VNM je sposobna da prepozna i klasifikuje različite vrste ulaznih podataka (uzoraka).

Problem.

Podeliti skup od četiri tačke $\{(-1,-1), (-1,+1), (+1,-1), (+1,+1)\}$ na dva, tri ili četiri neprazna podskupa.

Trivijalno, ali problem se komplikuje kako broj uzoraka i grupa raste


Sposobnost klasifikacije – maksimalni broj tačaka koje VNM može da klasifikuje, odnosno tačno identifikuje, i za koje može da generiše jedinstveni izlaz.

Prema sposobnosti klasifikacije VNM se dele na:


- ✓ linearne
- ✓ multilinearne
- ✓ nelinearne

VNM - linearni klasifikatori

x_1	x_2	Y
+1	+1	0
-1	+1	+1
+1	-1	0
-1	-1	0




Kako se ovo može upotrebiti?





x_1	x_2	Y
+1 (ON)	+1 (ON)	0 (OK)
-1 (OFF)	+1 (ON)	+1 (Alarm)
+1 (ON)	-1 (OFF)	0 (OK)
-1 (OFF)	-1 (OFF)	0 (OK)


VNM - multiliniarni klasifikatori



VNM - Ekskluzivno ILI



VNM – nelinearni klasifikatori



KRAJ