


# Linearna regresija

# Uvod

- Nadgledano učenje – zadati su ulaz i za njih dobijeni izlazi ( $m$  primera)  
 $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$



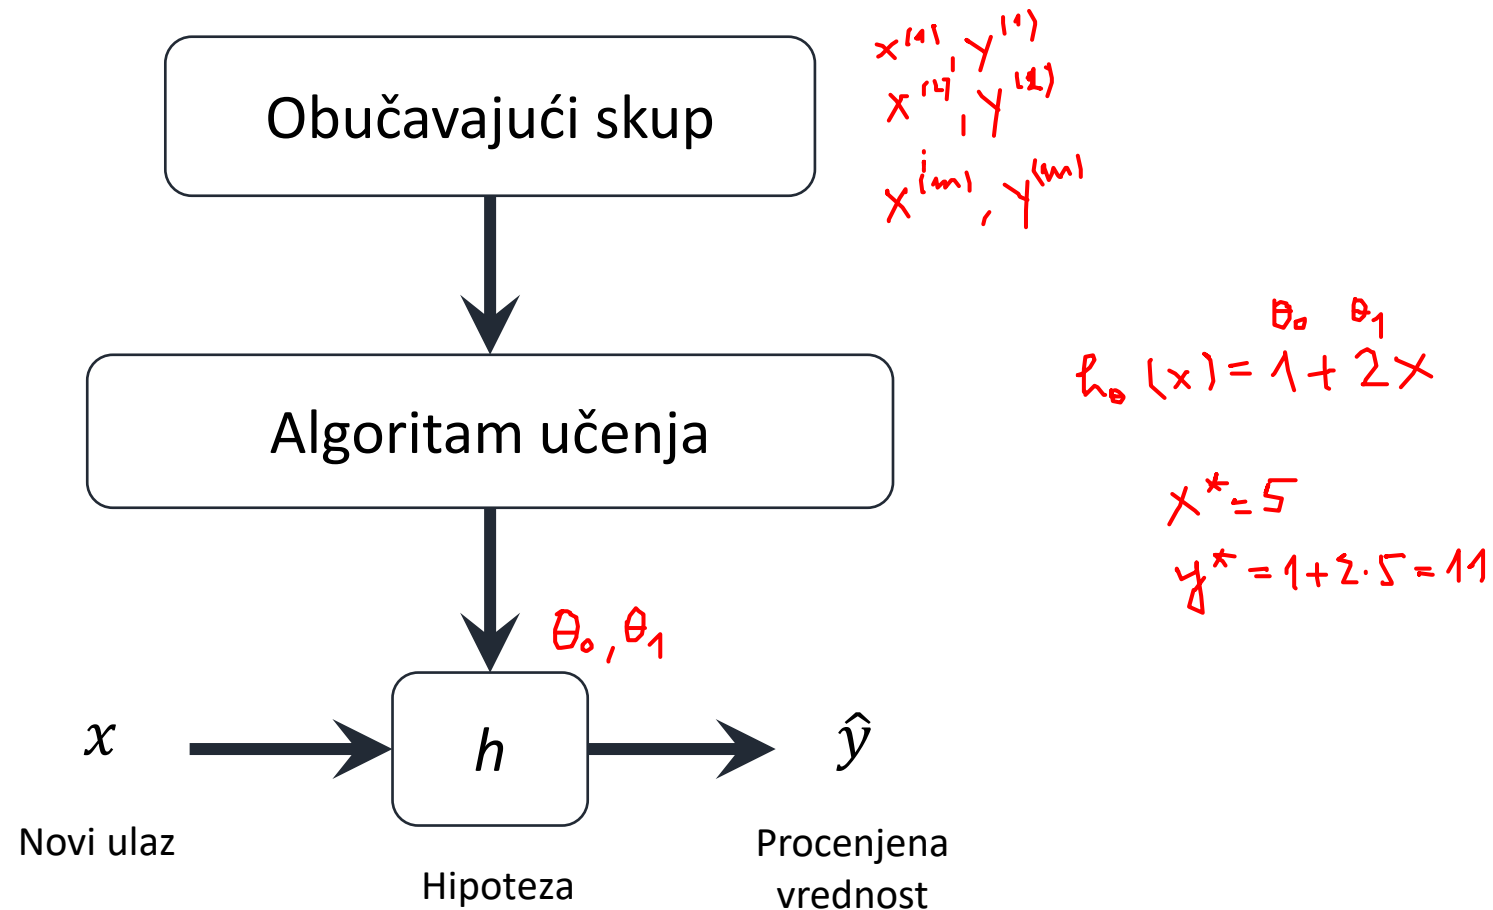
$$x \xrightarrow{h} y$$

$$x^* \rightarrow y^*$$

# Linarna regresija

- Za jednostavniji slučaj sa jednim promenljivom (ulazom):

$$\hat{y} = h_{\theta}(x) = \theta_0 + \theta_1 x$$



# Optimizacioni kriterijum

- Definiše se kriterijum

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 = \frac{1}{2m} \sum_{i=1}^m (\underbrace{h_{\theta}(x^{(i)})}_{\text{red handwritten } h_{\theta_0, \theta_1}(x^{(i)})} - y^{(i)})^2$$

- Kako odrediti parametre  $\theta_0$  i  $\theta_1$  da se dobije min  $J$  ?
- Za minimizaciju greške se može koristiti gradijentni postupak

# Gradijentni postupak

- Iterativni postupak

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$
$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{2m} \frac{\partial}{\partial \theta_j} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \underline{x_j^{(i)}} \quad x_0^{(i)} = 1$$

- Primena na Linearnu regresiju sa jednom promenljivom: ponavlja se do konvergencije

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot 1$$

$$J(\theta) < \epsilon$$

$$\theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

# Linearna regresija za više promenljivih

- Hipoteza  $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$
- Najčešće se uvodi dodatna promenljiva  
 $x_0 = 1$

Pa se dobije da je

$$h_{\theta}(x) = \theta^T x = x^T \theta = \theta_0 \underline{x_0} + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

gde je

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}, \quad x = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}$$

# Gradijentni postupak za linearnu regresiju sa više promenljivih

- Za linearnu regresiju sa više promenljivih

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) \quad j=1,2,\dots,n$$
$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{2m} \frac{\partial}{\partial \theta_j} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial}{\partial \theta_j} h_{\theta}(x^{(i)})$$

$$h_{\theta}(x^{(i)}) = \theta^T x^{(i)} = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}, \quad i = 1, 2, \dots, \underline{m}$$

pri čemu je  $x_0^{(i)} = 1$

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}, \quad \theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$


$$\theta_j = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$


# Vrste gradijentnog algoritma

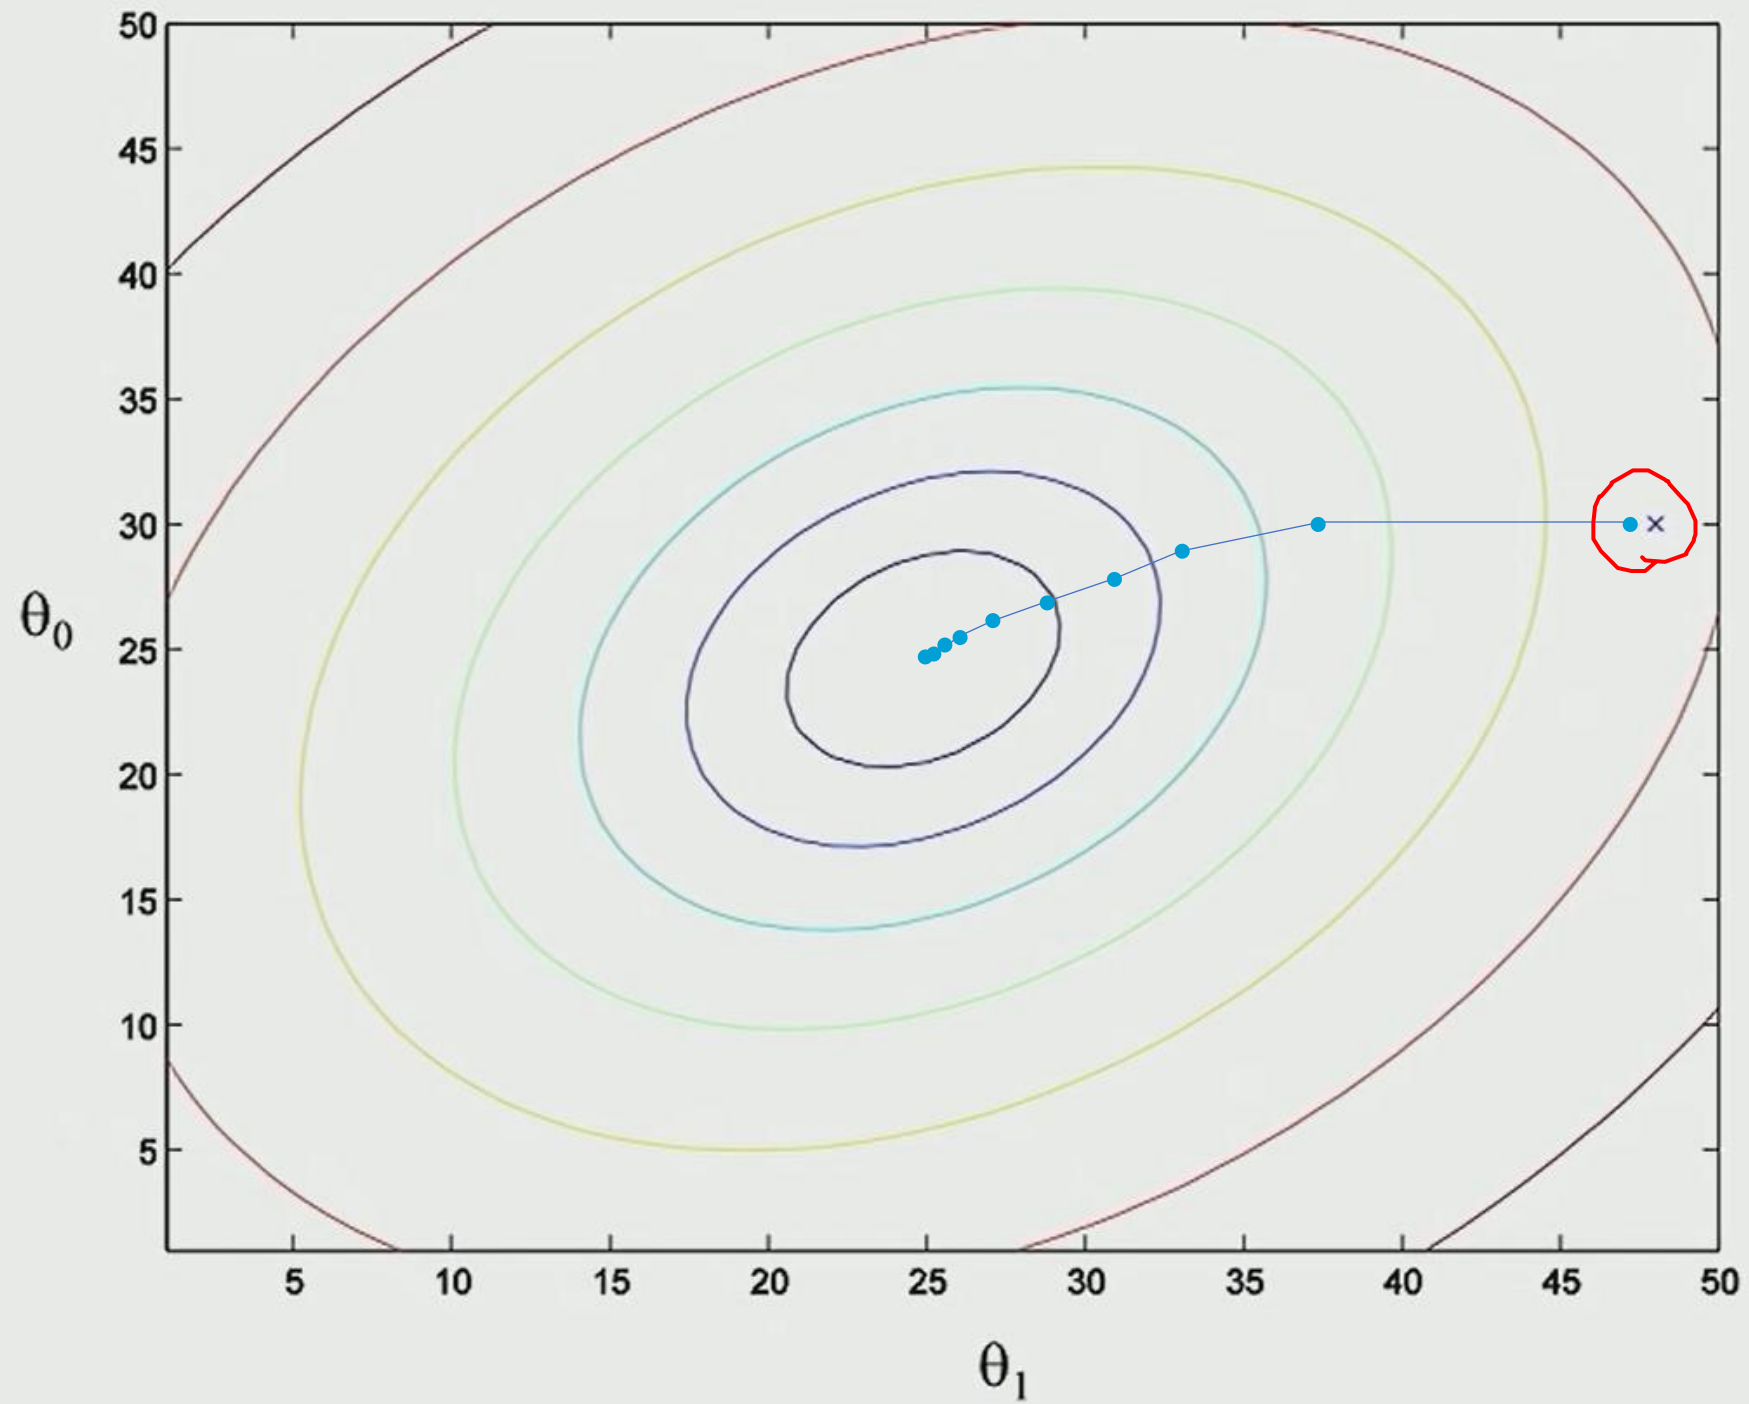
- Paketni ili „šaržni“ (*Batch Gradient Descent*)
  - Svi podaci se uzimaju odjednom u obzir
  - Nedostatak
    - Za veliku količinu podataka (npr.  $10^6$ ) svi se moraju učitati iz baze i sporije dolazi do rešenja
- Stohastički (*Stochastic Gradient Descent*)
  - Izvršava se u svakom koraku za npr. jedan slučajni podatak
    - Npr. Za cenu kuće, 1. korak za kuću 1, 2. korak za kuću 2, ...
  - Za veliko  $m$  je brži od Paketnog gradijentnog algoritma



# Gradijentni postupak












Prikaz estimacije po iteracijama



Kako izabrati faktor učenja  $\alpha$ ?



# Kako izabrati faktor učenja $\alpha$ ?



# Linearna regresija za više promenljivih

- Obučavajući skup  $(X, Y)$  se sastoji iz više primera  $(x^{(i)}, y^{(i)})$ ,  $i \in \{1, 2, \dots, m\}$ ,  $x^{(1)}$  tako npr.

	Površina (m <sup>2</sup> )	Broj spavaćih soba	Spratnost	Starost kuće (god)	Cena (€1000)
$x^{(1)}$	250	5	1	15	460
$x^{(2)}$	145	3	1	20	232
$x^{(3)}$	162	4	2	10	315
$x^{(4)}$	93	2	1	32	178

# Linearna regresija za više promenljivih

- Obučavajući skup  $(X, Y)$  se sastoji iz više primera  $(x^{(i)}, y^{(i)})$ ,  $i \in \{1, 2, \dots, m\}$ ,  $x^{(1)}$  tako npr.

$X$	$x_0$	$x_1$	$x_2$	$x_3$	$x_4$	$y$
$x^{(1)}$	1	250	5	1	15	460
$x^{(2)}$	1	145	3	1	20	232
$x^{(3)}$	1	162	4	2	10	315
$x^{(4)}$	1	93	2	1	32	178

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4$$

$$X = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ x^{(3)} \\ x^{(4)} \end{bmatrix} = \begin{bmatrix} 1 & 250 & 5 & 1 & 15 \\ 1 & 145 & 3 & 1 & 20 \\ 1 & 162 & 4 & 2 & 10 \\ 1 & 93 & 2 & 1 & 32 \end{bmatrix}$$

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \\ \theta_4 \end{bmatrix}$$

$$y = \begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \end{bmatrix}$$

$$\hat{y} = X \theta$$



# Normalna jednačina

Omogućuje analitičko određivanje parametara  $\theta$

$$X = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(m)} \end{bmatrix} = \begin{bmatrix} x_0^{(1)} & x_1^{(1)} & \dots & x_n^{(1)} \\ x_0^{(2)} & x_1^{(2)} & \dots & x_n^{(2)} \\ x_0^{(3)} & x_1^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \vdots \\ x_0^{(m)} & x_1^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \quad y = \begin{bmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad y = X \theta$$

# Normalna jednačina

- Polazi od optimizacionog kriterijuma  $J(\theta) = \frac{1}{2} (X\theta - y)^T (X\theta - y)$
- Predstavlja drugačiji način minimizacije  $J(\theta)$

$$\min J(\theta) \Leftrightarrow \nabla_{\theta} J(\theta) = 0$$

- Dobije se da je

$$\theta = (X^T X)^{-1} X^T y$$

# Kako izabrati algoritam za minimizaciju greške?


## Gradijenti postupak

- Prednosti
  - Dobro radi i za veliko  $n$
- Nedostaci
  - Izbor  $\alpha$
  - Iterativni postupak (često je potreban veliki broj iteracija)

## Normalna jednačina

- Prednosti
  - Ne treba birati  $\alpha$
  - Rešenje se dobija direktnim analitičkim proračunom
- Nedostaci
  - Potrebno odrediti inverznu matricu  $X^T X$ , problem za veliko  $n$  (složenost  $O(n^3)$ )
  - Spor - kada je  $n$  jako veliko
  - Matrica nema inverznu  $X^T X$

# Lokalno ponderisana linearna regresija



# Lokalno ponderisana linearna regresija

- Fituje se  $\theta$  za minimizaciju

$$\sum_{i=1}^m w^{(i)} (y^{(i)} - \theta^T x^{(i)})^2$$


gde je  $w^{(i)}$  težinska funkcija

$$w^{(i)} = \exp\left(-\frac{(x^{(i)} - x)^2}{2}\right)$$

Ako je  $|x^{(i)} - x|$  veliko,  $w^{(i)} \approx 0$  – mali uticaj na  $J$

$|x^{(i)} - x|$  malo,  $w^{(i)} \approx 1$

# Lokalno ponderisana linearna regresija



# Lokalno ponderisana linearna regresija

- Za izbor Gausove krive za  $w$  uvodu se parametar  $\tau$

$$w^{(i)} = \exp\left(-\frac{(x^{(i)} - x)^2}{2\tau^2}\right)$$

Za veće  $\tau$ ,  $w$  je manje – spušta se i podiže Gausova kriva

